طرح پیشنهادی پروژه درس تحلیل داده

تحلیل اخبار دروغین

آلاله احمدیان شالچی (93103703)

مقدمه:

اخبار دروغین[1]، نوعی از روزنامه‌نگاری زرد یا پروپگاندا است که شامل ایجاد شایعه یا اخبار گمراه‌کننده توسط شبکه‌های اجتماعی، روزنامه‌ها و دیگر روش‌های انتقال اخبار است. این اخبار بیشتر به قصد منحرف کردن خواننده برای از بین بردن اعتبار یک شرکت، نام، فرد، یا ایجاد اعنبار مالی یا سیاسی برای اشخاص، نوشته و چاپ می‌شوند. این اخبار در اغلب مواقع دارای تیترهای دروغگویانه و خودساخته‌اند که باعث جلب نظر خواننده‌ها و افزایش آن‌ها می‌شوند

در میانه‌ی سال 2016 نویسنده‌ی مدیا در buzzfeed متوجه یک رشته خبرهای خنده‌دار و نادرست شد که از یک شهر اروپای شرقی کوچک منشا گرفته‌بودند. با دنبای کردن منبع آن‌ها او به شهر ولز در مقدونیه رسید و شروع به بررسی این داستان‌ها کرد. او و دوستانش حداقل 140 سایت اخبار دروغین پیدا کردند که بازدید بسیار زیادی در گوگل داشتند. جوانان ولز احتمالا علاقه‌ی زیادی به سیاست در آمریکا نداشتند ولی به دلیل پول زیادی که از تبلیغات فیسبوک در می‌آوردند، می‌خواستند داستان‌هایشان به صورت گسترده در شبکه‌های اجتماعی پخش شوند و در آن زمان یکی از داغ‌ترین موضوعات انتخابات ریاست جمهوری دونالد ترامپ بودند.

در بازه‌ی انتخابات 2016 اخبار دروغین تبدیل به یک موضوع جهانی شدند و به صورت گسترده میلیون‌ها نفر به عنوان یکی از موضوعات مطرح دوره با آن آشنا شدند. بسیاری از منتقدان سیاسی و خبرنگاران اعلام کردند که سال 2016 سال اخبار دروغین بود و به عنوان یک نتیجه از این موضوع، سیاست و امنیت مجازی هیچ وقت به حالت قبل خود بازنمی‌گردد.

افراد دولتی در آمریکا و اروپا شروع به بازبینی قانون‌ها برای مبارزه با اخبار دروغین کردند، خصوصا زمانی که به عنوان یک کمپین هوشمند برنامه‌ریزی شده، شرکت‌های بزرگ تکنولوژی مانند فیسبوک و گوگل شروع به ایجاد روشی برای مبارزه با این اخبار در ادامه‌ی شناخته شدن جهانی آن‌ها کردند.. با یک نگاه کلی به گوگل-ترندز می‌توان افزایش جست‌وجو برای این موضوع را در اکتبر 2016 به وضوح دید.[1,2,3,4,5]

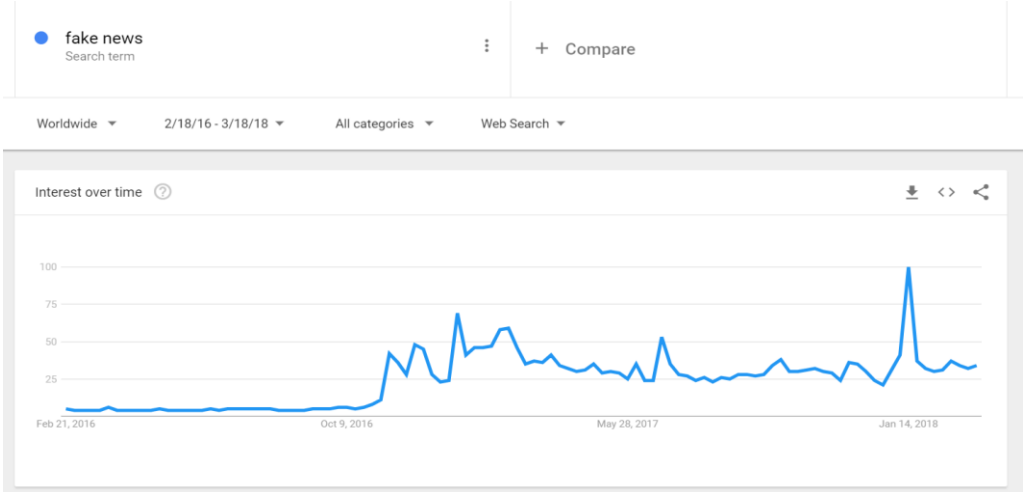

[1] Fake News

موضوع کلی:

هدف از این پروژه بررسی اخبار دروغین است، تا با استفاده از داده‌های موجود و تحلیل آن‌ها بتوانیم اطلاعات بیشتری در رابطه با آن‌ها از نظر زمانی به دست آوریم و همچنین بتوانیم با دقت نسبی برای خبرهای آینده راست یا دروغ بودن آن‌ها را تشخیص دهیم، در پایان با یک بررسی کلی تخمین میزنیم که نظر دونالد ترامپ تا چه حد درباره‌ی این اخبار درست است؟ (آیا شبکه‌هایی که به آن‌ها برچسب دروغ بودن زده است واقعا دروغگوتر از متوسط دروغگویی شبکه‌ها هستند؟)

جامعه آماری:

مجموعه‌ای مشخص از اخبار منتشر شده در چندین سایت منتخب در بازه‌ی زمانی نزدیک به انتخابات سال 2016 و درست یا نادرست بودن آن‌ها، تیتر و متن خبرهای منتشر شده در صفحه‌ی فیسبوک و شبکه‌های اجتماعی دیگر، میزان دیده شدن و بازخورد آن‌ها، درست یا ندرست بودن آن‌ها و زمان‌بندی آن‌ها.

سوالات مطرح‌شده:

- بررسی این که چه کلمات کلیدی‌ای در اخباری که راست نیستند بیشتر دیده می‌شود؟
- در طول یک بازه‌ی زمانی آیا سایت‌ها بیشتر به سمت راستگویی رفته‌اند یا دروغگویی؟
- کدام مراکز خبری اخبار دروغین بیشتری منتشر می‌کنند؟
- میزان بازخورد در اخبار دروغین نسبت به اخبار راست در سایت پخش‌کننده و شبکه‌های اجتماعی
- بررسی تعدادی از تئوری‌های موجود از جمله این که خبرهای دروغ به ضرر یکی از طرف‌های انتخابات بیشتر از دیگری بوده

اطلاعاتی که داریم:

چندین مجموعه داده برای بررسی راست و یا دروغ بودن اخبار منتشر شده در بازه‌های زمانی مشخص وجود دارد. ما در این پروژه از سه مجموعه‌ی زیر با فرمت CSV استفاده می‌کنیم.

1. مجموعه داده[2] های گرفته‌شده از سایت kaggle شامل متن و توضیحات مقاله از 244 وبسایت و 12999 پست در 30 روز از سال 2016 که با استفاده از webhose.io API جمع‌آوری شده است و راست یا دروغ بودن هر خبر همراه با زمان آن و منتشرکننده‌ی آن مشخص شده است.[6]
2. مجموعه داده‌های گرفته شده از فیسبوک مربوط به شبکه‌های خبری مختلف و راست و دروغ بودن آن‌ها شامل 2283 پست همراه با تعداد لایک، کامنت، بازبخش و زمان پست شدن.[7]
3. مجموعه 8000 تیتر و متن خبر و دروغ یا راست بودن آن‌ها[8]

[2] Dataset

کتابخانه‌ها:

- ✓ کتابخانه‌های readr و googlesheets برای خواندن داده‌ها
- ✓ کتابخانه‌های tidyr ، tidyverse و reshape2 برای مرتب کردن داده
- ✓ کتابخانه lubridate برای کار با داده‌ی زمان.
- ✓ کتابخانه‌ی gtrendsR برای به دست‌آوردن میزان تاثیرگذاری اخبار در هر زمان
- ✓ کتابخانه‌های NLP ، slam و tr برای تحلیل متن‌ها و زبان
- ✓ کتابخانه‌های ggplot2 و highcharter برای نشان دادن تحلیل‌ها به صورت تصویری
- ✓ کتابخانه‌های stringr و stringi برای کار کردن با رشته‌ها
- ✓ کتابخانه‌های kernlab و e1071 برای تحلیل داده‌ها و ترتیب دادن به آن‌ها

روش‌های تحلیل:

- ❖ روش‌های تحلیل از جمله تحلیل دینامیک تعداد اخبار غلط بر حسب زمان
- ❖ بررسی هیستوگرام تعداد دفعات وجود هر کلمه در مقاله‌های دروغین
- ❖ کورلیشن میان راست و دروغ بودن مقاله و تعداد علاقمندی، کامنت‌ها و بازپخش شدن آن
- ❖ بررسی نوع توزیع اخبار دروغین در طول زمان

منابع:

[1] http://www.bbc.com/news/blogs-trending-42724320
[2] https://en.wikipedia.org/wiki/Fake_news
[3] https://trends.google.com/trends/explore?date=2015-02-18%202018-03-18&q=fake%20news
[4] https://www.telegraph.co.uk/technology/0/fake-news-exactly-has-really-had-influence
[5] https://www.opendemocracy.net/jonathan-rose/fake-news-didn-t-start-with-donald-trump
[6] https://www.kaggle.com/mrisdal/fake-news
[7] https://github.com/BuzzFeedNews/2016-10-facebook-fact-check/tree/master/data
[8] https://github.com/GeorgeMcIntire/fake_real_news_dataset/blob/master/fake_or_real_news.csv.zip